

POSCAT AI Study: Introduction

What do models learn?

POSTECH Algorithm & AI Club · 2nd semester · 2026. 10. 8 · 김민준

이틀 전, OpenAI의 발표



openai.com, 2026년 10월 6일

- 내부 프런티어 모델이 도출한 새로운 수학 연구 결과를 공개
- 결과는 GitHub에, 다수의 증명은 **Lean**으로 형식화 (컴퓨터가 검증)
- 결과 하나에 든 연산량: 평균 **ChatGPT Pro** 약 3시간 추론 분량
- 대회 문제가 아니라 **연구 결과**

과학 연구의 투명성과 개방성을 높이기 위해, 결과를 도출한 과정에 관한 추가 세부 정보도 리포지터리에 공개합니다. 여기에는 모델의 추론 과정 요약 10건, ChatGPT에서의 Pro 사용량으로 환산한 연산량 추정치, 풀이를 시도한 문제 수에 관한 통계가 포함됩니다. 결과 하나를 도출하는 데 사용된 연산량은 평균적으로 ChatGPT Pro가 약 3시간 동안 추론하는 데 쓰는 연산량에 해당합니다.

AI가 연구자의 일을 대체하고 있다?

- 수학만 봐도, 1년 남짓 사이에

시점	무슨 일이 있었나
2025. 7	IMO: OpenAI, Google DeepMind의 모델이 금메달 수준
2025. 9	ICPC World Finals: OpenAI 시스템 12문제 전부 , Google DeepMind 10문제
2026. 10	OpenAI: 내부 모델이 도출한 새로운 수학 연구 결과 공개

- 정답이 있는 **대회 문제 풀기**에서, 아직 아무도 모르는 **연구 결과 찾기**로

정말 위협일까? 무엇이 대체되고, 무엇이 살아남을까?

왜 이런 일이 벌어졌을까?

- 모델은 무엇을, 어떻게 배우길래 1년 남짓 만에 대회 문제에서 연구 결과까지 왔을까?
- 왜 하필 수학이 먼저였을까? 다음은 어떤 분야일까?
- 그렇다면 연구자의 일 중 무엇이 대체되고, 무엇이 남을까?

모델이 어떻게 배우는지 알면,
우리가 무엇을 해야 할지 보인다

그래서 이번 학기의 질문: What do models learn?

오늘 순서

#	내용
0	왜 이 스터디인가: AI가 수학 연구를 한다면
1	홈페이지 둘러보기: Sessions, Reading, Mini game
2	발표 자리 volunteer
3	이 스터디의 방향: 왜 post-training인가, 이번 학기에 무엇을 공부하나

홈페이지: 한 학기의 질문

 POSCAT AI Study
POSTECH Algorithm & AI Club · 2nd semester

SessionsReadingMini game

What do models learn?

A semester of paper reading on how learning shapes capability, intent, and behavior.

1	2	3	4
Post-training RL	Alignment	Interpretability	Security
Build capability	Follow human intent	Understand learned behavior	Probe vulnerabilities



Tap the cat

고양이는 눌러 보세요 (Tap the cat)

- 한 학기의 질문: **What do models learn?**
- 학습이 모델의 **능력, 의도, 행동**을 어떻게 만드는지 논문으로 읽는다
- 네 파트
 - Post-training RL: 능력을 키운다
 - Alignment: 사람의 의도를 따른다
 - Interpretability: 배운 것을 이해한다
 - Security: 취약점을 찾는다
- 메뉴: Sessions · Reading · Mini game

Sessions: 8회, 목요일 22:00, 회당 논문 2편

Sessions

Eight sessions, Thursdays at 22:00, two papers each. Topics and presenters are added as they're decided.

1	Oct 8	Introduction	김민준	☑
2	Oct 15	To be announced	—	
3	Nov 5	To be announced	—	
4	Nov 12	To be announced	문정현	
5	Nov 19	To be announced	이우진, 장홍준	
6	Nov 26	To be announced	고정윤	
7	Dec 3	To be announced	정채현	
8	Dec 10	To be announced	—	

- 1회 (오늘): Introduction
- 발표자가 정해진 회차
 - 4회 문정현, 5회 이우진 · 장홍준
 - 6회 고정윤, 7회 정채현
- 비어 있는 회차: 2회, 3회, 8회
- 주제는 아직 전부 미정. 발표자가 정하면 홈페이지에 추가

발표 자리 volunteer

회차	날짜	발표자
2회	10월 15일 (목) 22:00	
3회	11월 5일 (목) 22:00	
8회	12월 10일 (목) 22:00	

- 주제는 **자유**: 이번 학기 네 파트 중 관심 있는 쪽에서 논문 2편
- 고르기 어렵다면 **Reading** 섹션의 입문 논문에서 출발
- 발표자가 이미 정해진 회차도, **주제가 정해지면 알려 주세요** → 홈페이지에 반영

Reading: 어디서부터 읽을까

 POSCAT AI Study
POSTECH Algorithm & AI Club · 2nd semester

SessionsReadingMini game

Where to start reading

Optional reading, not assigned session material.
One entry point for each part of the semester.

RL & Alignment Learning from feedback Explore how human feedback shapes a model. Start with the pipeline: supervised fine-tuning, reward modeling, and RL. Training language models to follow instructions with human feedback arXiv 2203.02155 Helps to know: supervised learning, rewards	Interpretability Inside the model Why can one neuron represent many features? Begin with the toy-model visualizations. Toy Models of Superposition arXiv 2209.10652 Helps to know: vectors, neural networks	Security Testing the boundaries Can aligned models withstand adversarial inputs? Start with the problem setup and the transfer experiments. Universal and Transferable Adversarial Attacks on Aligned Language Models arXiv 2307.15043 Helps to know: language models, optimization
--	--	--

- 발표 자료가 아닌 **선택 읽기**. 파트마다 입문 논문 하나
- 지금 들어가 있는 것
 - RL & Alignment: InstructGPT (Ouyang et al., 2022)
 - Interpretability: Toy Models of Superposition (Elhage et al., 2022)
 - Security: Universal and Transferable Adversarial Attacks (Zou et al., 2023)
- **파트별 추천 논문 목록은 아직 안 들어간 상태** → 채워 넣을 예정, 추천 환영

Mini game

Mini game

Small games made for fun between sessions. Your best score stays in this browser.

No. 1

Frontier Merge

Drop AI labs into the jar. Two of a kind merge into the next one up, nine tiers to the POSCAT cat.

Play

No. 2

Keep the Star Up

Swat the star before it falls. How long can POSCAT keep it in the air?

Coming soon

- 세션 사이에 쉬어 가는 작은 게임
- **Frontier Merge**: AI 연구소 로고를 떨어뜨려 같은 것끼리 합치기. 9단계 끝은 POSCAT 고양이
- 점수는 **리더보드로 공유**. 1위 기록에 도전해 보세요
- **Keep the Star Up**: 준비 중

Frontier Merge


← All games

Score
996

Best
2207

Hide dashboard

Pause



Leaderboard


Top 5

1 **Minjoon Kim** **2207**

Won · 10월 8일

Scores are shared with everyone.

왜 post-training인가



- LLM 사전학습은 너무 비싸다 → 이미 빅테크가 사전학습한 모델을 **후속학습**하는 연구가 지금 가장 뜨거운 분야
- 같은 base model도 후속학습에 따라 **추론을 잘하는 모델, 말을 잘 듣는 모델, 해악을 끼치지 않는 모델**이 된다
- 그리고 그렇게 학습된 모델이 **무엇을 배웠는지** 들여다보는 연구가 함께 간다

이번 학기에 공부할 것

파트	질문	키워드 (예시)
Post-training RL	추론 능력을 어떻게 늘리나	RLHF, RLVR, PPO, GRPO, DeepSeek-R1
Alignment	사람의 의도에 맞게 행동하게 하려면	InstructGPT, DPO, Constitutional AI
Security	해악을 끼치지 않는가, 공격에 버티는가	jailbreak, adversarial suffix, red teaming
Interpretability	이미 학습된 모델 안에서 무슨 일이 일어나나	superposition, sparse autoencoder, circuits

- 추론 능력만이 아니라 **의도대로 행동하기, 해악 피하기, 모델 해석하기**까지 두루
- 공통 질문은 하나: **What do models learn?**

키워드는 예시. 실제로 읽을 논문은 각 회차 발표자가 고른다

정리, 그리고 부탁

- 진행: **매주 목요일 22:00, 8회, 회당 논문 2편**. 발표자가 주제와 논문을 고르고 홈페이지에 반영
- 방향: 사전학습된 LLM의 **후속학습**을 중심으로, 능력 · 의도 · 해악 · 해석을 두루
- 부탁
 - 비어 있는 발표 자리: **2회 (10/15), 3회 (11/5), 8회 (12/10)**
 - Reading에 넣을 추천 논문
 - Mini game 기록 경신