

Post-training RL 1부: REINFORCE에서 PPO까지

그리고 LLM post-training으로 · POSCAT 논문 스터디 · 발표일 · 김민준

이런 식, 보고 겁먹은 적 있나요?

We propose the **D**ecouple Clip and **D**ynamic **s**Ampling **P**olicy **O**ptimization (DAPO) algorithm. DAPO samples a group of outputs $\{o_i\}_{i=1}^G$ for each question q paired with the answer a , and optimizes the policy via the following objective:

$$\begin{aligned} \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \\ & \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right] \\ \text{s.t. } & 0 < \left| \{o_i \mid \text{is_equivalent}(a, o_i)\} \right| < G, \end{aligned} \quad (8)$$

where

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}, \quad \hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (9)$$

The full algorithm can be found in Algorithm 1. In this section, we will introduce the key techniques associated with DAPO.

사실, 이해하고 나면 간단한 식입니다


오늘이 끝나면 ratio, clip, advantage, 평균과 표준편차까지 이 식의 기호를 하나씩 읽을 수 있습니다

1부 흐름

#	주제	질문
0	RL 기초	MDP, tower property, Bellman 방정식, TD learning, Q-learning
1	Policy optimization 흐름	REINFORCE → A2C → TRPO → PPO, 각 단계는 무엇을 해결했나
2	게임 에이전트에서 LLM으로	같은 알고리즘이 LLM에서는 어떻게 대응되나
3	LLM post-training 도입	reward는 어디서 오나 (RLHF vs RLVR), 모든 방법을 하나의 policy gradient로 보기
2부	RLVR과 GRPO, 그 이후 (다음 시간)	RL 이전의 추론 강화 → DeepSeek-R1 → Kimi k1.5, DAPO, CISPO → ScaleRL → 비판적 시각

0. MDP: agent와 environment의 상호작용

- **MDP** = (S, A, P, r, γ). 다음 상태는 현재 (s_t, a_t)에만 의존 (**Markov 성질**)



- **목표:** 누적 **reward (return)**의 기댓값을 **최대화**하는 policy π 를 찾는다

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}, \quad J(\pi) = \mathbb{E}_{\pi}[G_0], \quad \pi^* = \operatorname{argmax}_{\pi} J(\pi)$$

- **가치 함수:** 상태 (와 행동)에서 출발했을 때의 기대 return

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s], \quad Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a]$$

agent는 P와 r을 모른다 → 샘플(경험)만 보고 학습 (model-free). LLM 대응은 2장: 상태 = prompt + 생성한 토큰, 행동 = 다음 토큰

0. 도구: 조건부 기댓값과 tower property

- $\mathbb{E}[X | Y = y]$ 는 숫자이고 y 의 함수 $g(y)$. $\mathbb{E}[X | Y] := g(Y)$ 는 Y 의 함수인 **확률변수**
 - 예: $X =$ 학생 점수, $Y =$ 반이면 $\mathbb{E}[X | Y] =$ 그 학생이 속한 반의 평균

$$g(y) := \mathbb{E}[X | Y = y] = \sum_x x \Pr(X = x | Y = y), \quad \mathbb{E}[X | Y] := g(Y)$$

- **Tower property** (law of total expectation): 조건을 걸었다가 다시 평균내면 원래 기댓값

$$\boxed{\mathbb{E}[\mathbb{E}[X | Y]] = \mathbb{E}[X], \quad \mathbb{E}[\mathbb{E}[X | Y, Z] | Y] = \mathbb{E}[X | Y]}$$

오른쪽 식을 $Y = y$ 에서 읽으면 $\mathbb{E}[\mathbb{E}[X | Y, Z] | Y = y] = \mathbb{E}[X | Y = y]$. 바깥 조건 Y 가 안쪽 조건에도 들어 있어야 한다

$$\begin{aligned} \mathbb{E}[g(Y)] &= \sum_y \Pr(Y = y) \sum_x x \Pr(X = x | Y = y) && \text{이산 증명: 정의대로 풀기} \\ &= \sum_x x \sum_y \Pr(X = x, Y = y) = \sum_x x \Pr(X = x) = \mathbb{E}[X] && \text{순서 교환} \rightarrow Y \text{를 주변화} \end{aligned}$$

- **Pull-out**: Y 를 알면 $f(Y)$ 는 상수. $\mathbb{E}[f(Y) X | Y] = f(Y) \mathbb{E}[X | Y]$
- **이 발표에서의 쓰임**: 조건에 a_t, s_{t+1} 같은 변수를 끼워 넣었다가 다시 평균낸다 $\rightarrow$ Bellman 방정식 (0장), policy gradient theorem (1장)

0. V의 Bellman 방정식

- 출발점은 return의 재귀 $G_t = r_t + \gamma G_{t+1}$. 여기에 $s_t = s$ 로 조건부 기댓값을 씌운다

$$V^\pi(s) = \mathbb{E}[r_t + \gamma G_{t+1} \mid s_t = s]$$

$$= \mathbb{E}[r_t \mid s_t = s] + \gamma \mathbb{E}[G_{t+1} \mid s_t = s]$$

$$= \mathbb{E}[r_t \mid s_t = s] + \gamma \mathbb{E}[\mathbb{E}[G_{t+1} \mid s_t, a_t, s_{t+1}] \mid s_t = s]$$

$$= \mathbb{E}[r_t \mid s_t = s] + \gamma \mathbb{E}[V^\pi(s_{t+1}) \mid s_t = s]$$

$$= \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) [r(s, a) + \gamma V^\pi(s')]$$

- 미래 전체의 기댓값이 다음 상태 하나의 V로 요약된다 (Markov 성질 덕분)
- 근사는 없다: 항등식 1번 + tower property 1번 + Markov 성질 1번
- 다음 장: 이 식의 기댓값 안을 샘플 하나로 바꾸면 **TD learning**

V의 정의 + $G_t = r_t + \gamma G_{t+1}$

선형성

tower property (앞 장의 $Y = y$ 형태): $X = G_{t+1}$, $Y = s_{t'}$
 $Z = (a_{t'}, s_{t+1})$, $y = s$

Markov 성질: 안쪽 $\mathbb{E}[\cdot] = V^\pi(s_{t+1})$ (확률변수)

$a_t \sim \pi$, $s_{t+1} \sim P$ 로 풀어 쓰고 다시 묶기

0. TD learning: Bellman 방정식을 샘플 하나로

- V^π 는 두 가지 기댓값으로 쓸 수 있다. 기댓값 안의 **샘플 하나**를 target으로 쓰면

$$V^\pi(s) = \mathbb{E}[G_t \mid s_t = s]$$

정의 → 샘플 G_t : Monte Carlo

$$V^\pi(s) = \mathbb{E}[r_t + \gamma V^\pi(s_{t+1}) \mid s_t = s]$$

Bellman 방정식 → 샘플 $r_t + \gamma V(s_{t+1})$: TD(0)

- 현재 추정 $V(s_t)$ 를 target 쪽으로 α 만큼 옮긴다. TD에서 **target - $V(s_t)$** 가 **TD error**

$$V(s_t) \leftarrow V(s_t) + \alpha \delta_t, \quad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

$V = V^\pi$ 이면 $\mathbb{E}[\delta_t \mid s_t] = 0$ (Bellman 방정식 그 자체). $\delta_t \neq 0$ 인 방향으로 V 를 고치면 해로 다가간다

	Monte Carlo	TD(0)
target	G_t (실제 return)	$r_t + \gamma V(s_{t+1})$ (추정치 사용)
업데이트 시점	에피소드가 끝난 뒤	매 step
bias / variance	bias 없음 / variance 큼 (미래 전체의 무작위성)	V 가 틀리면 bias / variance 작음 (한 step만)

δ_t 는 1장의 A2C critic과 GAE에 그대로 다시 나온다

0. Q의 Bellman 방정식: tower property로 유도

- V와 같은 단계, 이번에는 a_t 까지 고정. 표기: $\mathbb{E}[\cdot | s, a] := \mathbb{E}_\pi[\cdot | s_t = s, a_t = a]$, $r(s, a) := \mathbb{E}[r_t | s, a]$

$$Q^\pi(s, a) = \mathbb{E}[r_t + \gamma G_{t+1} | s, a]$$

$$= r(s, a) + \gamma \mathbb{E}[\mathbb{E}[G_{t+1} | s, a, s_{t+1}] | s, a]$$

$$= r(s, a) + \gamma \mathbb{E}[V^\pi(s_{t+1}) | s, a]$$

$$\boxed{= r(s, a) + \gamma \sum_{s'} P(s'|s, a) \sum_{a'} \pi(a'|s') Q^\pi(s', a')}$$

Q의 정의 + $G_t = r_t + \gamma G_{t+1}$

선형성 + **tower property**: $X = G_{t+1}$, $Y = (s_t, a_t)$, $Z = s_{t+1}$

Markov 성질 (V 때와 같다)

$s_{t+1} \sim P$, 그리고 아래의 $V = \sum \pi Q$

- 마지막 줄의 $V \rightarrow Q$ 도 **tower property**: 이번에는 조건에 a_{t+1} 을 끼워 넣는다 ($a_{t+1} | s_{t+1} \sim \pi$)

$$V^\pi(s') = \mathbb{E}[G_{t+1} | s_{t+1} = s'] = \mathbb{E}[\mathbb{E}[G_{t+1} | s_{t+1}, a_{t+1}] | s_{t+1} = s'] = \sum_{a'} \pi(a'|s') Q^\pi(s', a')$$

정리: $V = \mathbb{E}_{a \sim \pi}[Q]$, $Q = r + \gamma \mathbb{E}_{s' \sim P}[V]$. 이 식을 샘플로 근사하면 (a' 을 π 로 샘플) SARSA

0. Bellman optimality: max는 어디서 오나

- 앞 장의 $\sum_{a'} \pi(a'|s') Q(s', a')$ 는 **가중평균**이라 $\max_{a'} Q(s', a')$ 보다 작거나 같다 → 일반 π 에서 max로 바꾸면 틀린 식
- max가 맞는 것은 π 가 그 Q 에 대해 **greedy**일 때뿐. 그리고 greedy 정책이 바로 **최적 정책**이다

$$Q^*(s, a) = r(s, a) + \gamma \sum_{s'} P(s'|s, a) \max_{a'} Q^*(s', a'), \quad \pi^*(s) = \operatorname{argmax}_a Q^*(s, a)$$

tower property로 읽으면: π^* 에 앞 장의 식을 그대로 쓰고, π^* 가 greedy라 $\mathbb{E}_{a' \sim \pi^*}[Q^*] = \max_{a'} Q^*$

왜 greedy가 최적인가 (증명 스케치)

- (1) $\mathcal{T}Q := r + \gamma \sum_{s'} P \max_{a'} Q$ 는 γ -contraction ($|\max f - \max g| \leq \max |f - g|$) → 유일한 fixed point $\tilde{Q}$
- (2) 임의의 π : $Q^\pi = \mathcal{T}^\pi Q^\pi \leq \mathcal{T} Q^\pi \leq \mathcal{T}^2 Q^\pi \leq \dots \rightarrow \tilde{Q}$ (평균 $\leq$ max, $\mathcal{T}$ 는 단조) → **모든 π 에 대해 $Q^\pi \leq \tilde{Q}$**
- (3) $\tilde{Q}$ 에 대해 greedy인 $\tilde{\pi}$: $\mathcal{T}^{\tilde{\pi}} \tilde{Q} = \mathcal{T} \tilde{Q} = \tilde{Q}$ 이므로 $Q^{\tilde{\pi}} = \tilde{Q} \rightarrow$ **상한이 달성된다**, 따라서 $Q^* = \tilde{Q}$

$\mathcal{T}^\pi$ 는 max 대신 $\sum_{a'} \pi(a'|s')$ 를 쓴 연산자 (앞 장: $Q^\pi = \mathcal{T}^\pi Q^\pi$). 순서 주의: s' 을 본 뒤 행동을 고르므로 $\mathbb{E}_{s'}[\max_{a'} Q]$

0. Q-learning, 그리고 policy gradient로 넘어가는 이유

- Bellman 방정식의 $\mathbb{E}_{s' \sim p}$ 를 환경이 준 샘플 s_{t+1} 하나로 대신해서 TD 방식으로 푼다

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)]$$

	SARSA	Q-learning
근사하는 식	Bellman expectation (Q^π)	Bellman optimality (Q^*)
target	$r_t + \gamma Q(s_{t+1}, a_{t+1})$	$r_t + \gamma \max_{a'} Q(s_{t+1}, a')$
a'	π 로 실제 샘플	샘플하지 않고 max 로 계산
데이터	on-policy: 지금의 π 로 모아야 한다	off-policy : 데이터가 담당하는 건 $s' \sim p$ 뿐 (π 와 무관)

- **DQN** (Mnih et al., 2015): Q를 신경망으로, replay buffer와 target network로 안정화 → Atari
- **Value-based의 한계**: 행동마다 $\max_a Q$ 가 필요하다. action 공간이 크거나 연속이면 어렵다
 - LLM: 어휘가 10만 개 단위, 응답은 토큰 시퀀스라 조합적. 그리고 LLM은 그 자체로 확률적 **policy** π_θ
- → value를 거치지 않고 **policy**를 직접 최적화하자: **policy gradient** (1장)

1. REINFORCE: 샘플만으로 gradient 추정

- 목표: trajectory 전체의 **누적 reward(return)** 최대화. $R(\tau)$ 가 바로 그 누적 reward

$$R(\tau) = \sum_{t=0}^T \gamma^t r_t, \quad J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)]$$

- 기댓값이 π_θ 에서 뽑은 샘플에 대한 것이라 그대로는 미분할 수 없다 → **log-derivative trick** $\nabla_\theta p_\theta = p_\theta \nabla_\theta \log p_\theta$

$$\nabla_\theta J = \nabla_\theta \int p_\theta(\tau) R(\tau) d\tau = \int p_\theta(\tau) \nabla_\theta \log p_\theta(\tau) R(\tau) d\tau = \mathbb{E} [R(\tau) \cdot \nabla_\theta \log p_\theta(\tau)]$$

$$\log p_\theta(\tau) = \log p(s_0) + \sum_t \log \pi_\theta(a_t | s_t) + \sum_t \log P(s_{t+1} | s_t, a_t)$$

- 환경 dynamics P 항은 θ 와 무관해서 미분하면 사라진다 → **환경 모델 없이 샘플만으로 추정** (Monte Carlo)

$$\nabla_\theta J = \mathbb{E} [\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot R(\tau)]$$

1. $R(\tau)$ 대신 미래 reward만 남기기 (reward-to-go)

- 시점 t 의 action은 **과거 reward**를 바꿀 수 없다 (causality). $R(\tau)$ 를 과거와 미래로 나누고, $Z_t := \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$
- trajectory를 **과거** $h_t = (s_0, a_0, r_0, \dots, s_t)$ / **현재** a_t / **미래** $\tau_{>t} = (r_t, s_{t+1}, a_{t+1}, \dots)$ 로 자른다

$$p_{\theta}(\tau) = p_{\theta}(h_t) \cdot \pi_{\theta}(a_t | s_t) \cdot p_{\theta}(\tau_{>t} | h_t, a_t)$$

- **과거 항** ($t' < t$)은 기댓값이 **0**이다. 정의대로 풀어서 확인하는 것은 다음 장

$$\mathbb{E}[Z_t r_{t'}] = 0 \quad (t' < t)$$

직관: 시점 t 의 행동은 이미 받은 reward와 무관하게 뿜힌다. 그 reward를 곱해 봐야 평균적으로는 0

- 따라서 **미래 항만 남는다**. 기댓값은 그대로, 노이즈인 과거 항이 빠져 **분산이 작아진다**

$$\nabla_{\theta} J = \mathbb{E} \left[\sum_t \sum_{t' \geq t} \gamma^{t'} Z_t r_{t'} \right] = \mathbb{E} \left[\sum_t \gamma^t Z_t G_t \right], \quad G_t := \sum_{t'=t}^T \gamma^{t'-t} r_{t'}$$

실제 구현은 γ^t 를 빼고 G_t 만 쓰는 것이 관례 ($\gamma = 1$ 이면 같다). 용어는 CS285, Spinning Up에서 주로 쓰임 (Sutton & Barto는 return G_t)

1. 과거 항이 사라지는 이유: 기댓값을 정의대로 풀기

- $Z_t := \nabla_{\theta} \log \pi_{\theta}(a_t|s_t)$, $t' < t$. trajectory를 과거 h_t / 현재 a_t / 미래 $\tau_{>t}$ 로 나눈다

$$\begin{aligned}\mathbb{E}[Z_t r_{t'}] &= \sum_{\tau} p_{\theta}(\tau) Z_t r_{t'} \\ &= \sum_{h_t} \sum_{a_t} \sum_{\tau_{>t}} p_{\theta}(h_t) \pi_{\theta}(a_t|s_t) p_{\theta}(\tau_{>t}|h_t, a_t) Z_t r_{t'} \\ &= \sum_{h_t} p_{\theta}(h_t) r_{t'} \sum_{a_t} \pi_{\theta}(a_t|s_t) Z_t \sum_{\tau_{>t}} p_{\theta}(\tau_{>t}|h_t, a_t) \\ &= \sum_{h_t} p_{\theta}(h_t) r_{t'} \sum_{a_t} \pi_{\theta}(a_t|s_t) Z_t \cdot 1 \\ &= \sum_{h_t} p_{\theta}(h_t) r_{t'} \sum_{a_t} \nabla_{\theta} \pi_{\theta}(a_t|s_t)\end{aligned}$$

$$\boxed{= \sum_{h_t} p_{\theta}(h_t) r_{t'} \nabla_{\theta} \sum_{a_t} \pi_{\theta}(a_t|s_t) = \sum_{h_t} p_{\theta}(h_t) r_{t'} \nabla_{\theta} 1 = 0}$$

기댓값의 정의: trajectory마다 확률 $\times$ 값

$\tau = (h_t, a_t, \tau_{>t})$ 로 나누고 연쇄 법칙으로 분해

합 순서 정리: $r_{t'}$ 은 h_t 에, Z_t 는 (s_t, a_t) 에만 의존
→ 바깥 합으로

조건부 분포의 합 = 1 (미래는 여기서 끝)

$$\pi \nabla \log \pi = \nabla \pi$$

합과 미분 교환, 확률의 합 = 1

5-6줄이 score 항등식 $\mathbb{E}_{a \sim \pi} [\nabla \log \pi] = 0$. 같은 논리로 h_t 에서 정해지는 아무 Y (예: baseline $b(s_t)$)에 대해 $\mathbb{E}[Z_t Y] = 0 \rightarrow A2C$

1. Return은 Q의 샘플: Policy Gradient Theorem

- 이번에는 h_t 가 아니라 (s_t, a_t) 로 조건을 건다 ($Z_t := \nabla_{\theta} \log \pi_{\theta}(a_t|s_t)$)

$$\begin{aligned}
 \nabla_{\theta} J &= \sum_t \gamma^t \mathbb{E}[Z_t G_t] \\
 &= \sum_t \gamma^t \mathbb{E}[\mathbb{E}[Z_t G_t | s_t, a_t]] \\
 &= \sum_t \gamma^t \mathbb{E}[Z_t \mathbb{E}[G_t | s_t, a_t]] \\
 &= \sum_t \gamma^t \mathbb{E}[Z_t Q^{\pi}(s_t, a_t)] \\
 &= \mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_t \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) Q^{\pi}(s_t, a_t) \right] \\
 &= \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^{\pi}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) Q^{\pi}(s, a)]
 \end{aligned}$$

앞 장의 결과 (기댓값의 선형성)

tower property: $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}]]$

pull-out: Z_t 는 (s_t, a_t) 의 함수

Q의 정의: $Q^{\pi}(s, a) := \mathbb{E}[G_t | s_t = s, a_t = a]$

선형성을 거꾸로: 다시 하나의 기댓값으로

할인 방문 분포 d^{π} 로 묶기 (무한 horizon, 다음 장에서 유도)

- 과거 항은 a_t **이전**(h_t)으로 조건 $\rightarrow$ 사라짐. 미래 항은 a_t **까지**((s_t, a_t))로 조건 $\rightarrow$ **Q로 남음**
- G_t 는 Q^{π} 의 **Monte Carlo 샘플**. 다음 장: baseline V 를 빼면 $\mathbf{A} = \mathbf{Q} - \mathbf{V}$. LLM은 $G_t = R(\tau)$ 라 baseline이 필수 (2부 5장 GRPO)

유한 horizon이면 Q 는 남은 길이에 따라 Q^{π_t} . 마지막 줄은 무한 horizon ($\gamma < 1$, 유계 reward, 적분 가능한 score $\rightarrow$ Fubini), stationary라 $Q^{\pi_t} = Q^{\pi}$

1. 할인 방문 분포로 묶기

- 앞 장의 박스 식에서 출발. $f(s, a) := \nabla_{\theta} \log \pi_{\theta}(a|s) Q^{\pi}(s, a)$ 로 두고 **상태별로 다시 묶는다**

$$\begin{aligned}
 \nabla_{\theta} J &= \mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_t \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) Q^{\pi}(s_t, a_t) \right] \\
 &= \sum_t \gamma^t \mathbb{E}[f(s_t, a_t)] \\
 &= \sum_t \gamma^t \sum_{\tau} p_{\theta}(\tau) f(s_t, a_t) \\
 &= \sum_t \gamma^t \sum_{s, a} \Pr(s_t = s, a_t = a) f(s, a) \\
 &= \sum_t \gamma^t \sum_s \Pr(s_t = s) \sum_a \pi_{\theta}(a|s) f(s, a) \\
 &= \sum_s \rho^{\pi}(s) \sum_a \pi_{\theta}(a|s) f(s, a) \\
 &= \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi}, a \sim \pi_{\theta}} [f(s, a)]
 \end{aligned}$$

앞 장의 박스 식 (Policy Gradient Theorem)

선형성, f의 정의

기댓값의 정의: trajectory 전체에 대한 합

f는 (s_t, a_t) 만 읽는다 $\rightarrow \tau$ 를 그 값으로 **묶으면** 나머지 좌표는 합해서 사라짐

$$\Pr(s_t = s, a_t = a) = \Pr(s_t = s) \pi_{\theta}(a|s)$$

$$\text{순서 교환 (Fubini), } \rho^{\pi}(s) := \sum_t \gamma^t \Pr(s_t = s)$$

$$\text{정규화: } d^{\pi}(s) := (1-\gamma) \rho^{\pi}(s)$$

- ρ^{π} 는 확률분포가 아니다: $\sum_s \rho^{\pi}(s) = \sum_t \gamma^t = \mathbf{1}/(1-\gamma) \rightarrow (1-\gamma)$ 를 곱해 정규화한 것이 d^{π} , 그래서 앞에 $1/(1-\gamma)$
- 해석: 매 step $1-\gamma$ 확률로 멈출 때 **멈춘 시점의 상태 분포**. (주의: γ^t 를 빼는 구현 관례는 엄밀히는 이 gradient가 아니다, Nota & Thomas)

1. Policy gradient의 문제: 계수의 분산

- 지금까지 얻은 식 (Policy Gradient Theorem): $\nabla \log \pi$ 에 **Q를 곱한 것**의 기댓값

$$\nabla_{\theta} J = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_{\theta}}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi}(s, a)]$$

샘플로는 Q 대신 G_t (Monte Carlo)

- 문제: 방향을 정하는 계수가 Q의 **절대 크기**. reward가 모두 양수면 **뽐힌 행동은 무엇이든** 확률이 크게 오른다

한 상태 s의 행동	Q(s, a)	Q를 계수로 쓰면 (뽐혔을 때)	평균 100을 빼면
a_1	101	확률을 크게 올림 (+101)	조금 올림 (+1)
a_2	100	확률을 크게 올림 (+100)	그대로 (0)
a_3 (가장 나쁨)	99	확률을 크게 올림 (+99)	조금 내림 (-1)

- 기댓값으로는 결국 a_1 쪽으로 가지만 그 신호는 **차이 1**뿐. 샘플 하나하나는 "뽐힌 것을 약 100만큼" 민다
- 어떤 행동이 뽐히느냐에 따라 gradient가 크게 흔들린다 = **분산이 크다**. 계수에서 **평균을 빼자**

1. Q 대신 Advantage: 이 행동이 평균보다 나은가

- Q 대신 $A = Q - V$ 를 곱한다. $V(s) = \mathbb{E}_{a \sim \pi} [Q(s, a)]$ 는 그 상태의 평균, A는 평균보다 얼마나 나은가

$$\nabla_{\theta} J = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^{\pi_{\theta}}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot A^{\pi}(s, a)], \quad A^{\pi} = Q^{\pi} - V^{\pi}$$

$A > 0$ 이면 확률을 올리고, $A < 0$ 이면 내린다. 앞 장 예시의 +1, 0, -1

- 그런데 왜 같은가? Q를 A로 바꾼 것은 $\nabla \log \pi \cdot V(s)$ 를 뺀 것. 이 항의 기댓값이 0이면 gradient는 그대로

$$\begin{aligned} \mathbb{E}_{a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot V^{\pi}(s)] &= V^{\pi}(s) \sum_a \pi_{\theta}(a|s) \nabla_{\theta} \log \pi_{\theta}(a|s) && V(s) \text{는 } a \text{와 무관} \rightarrow \text{합 밖으로} \\ &= V^{\pi}(s) \sum_a \nabla_{\theta} \pi_{\theta}(a|s) && \pi \nabla \log \pi = \nabla \pi \\ &= V^{\pi}(s) \nabla_{\theta} \sum_a \pi_{\theta}(a|s) && \text{합과 미분 교환} \\ &= V^{\pi}(s) \nabla_{\theta} 1 = 0 && \text{확률의 합} = 1 \text{ (score 항등식, 과거 항 증명과 같다)} \end{aligned}$$

- 상태마다 0이므로 $s \sim d^{\pi}$ 위에서 평균해도 0 $\rightarrow$ 기댓값은 그대로, 계수가 평균 근처로 줄어 분산이 작아진다
- a에 의존하지 않는 아무 $b(s)$ 나 같은 이유로 빼도 된다 (**baseline**). V는 "평균"이라는 해석이 자연스러운 선택

1. A2C: critic으로 advantage 추정

- V^π 는 모른다 $\rightarrow$ **critic** $V_\phi \approx V^\pi$ 를 따로 학습 (actor π_θ + critic V_ϕ = **actor-critic**)

$$A(s_t, a_t) \approx \delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$$

$\mathbb{E}[\delta_t | s_t, a_t] = Q(s_t, a_t) - V(s_t) = A$ ($V_\phi = V^\pi$ 일 때). 0장의 TD error가 그대로 advantage 추정치

	역할	업데이트
actor π_θ	행동을 고른다	$\nabla_\theta \log \pi_\theta(a_t s_t) \cdot \delta_t$ 방향으로 (확률 올리기/내리기)
critic V_ϕ	상태의 가치를 평가한다	δ_t^2 최소화 (0장 TD, target은 상수 취급)

- critic이 예측하는 것은 V . s_{t+1} 은 rollout에서 이미 관측했으니 δ_t 를 계산할 수 있다
- 남은 문제: **step size**. lr이 조금만 커도 policy가 망가지고, 망가진 policy로 데이터를 다시 모으므로 회복이 어렵다

1. TRPO: Trust Region으로 안정적인 업데이트

- 질문: gradient ascent가 lr에 민감하지 않고 objective를 단조 증가시키게 할 수 있을까?

$$\boxed{\begin{array}{l} \max_{\theta} \mathbb{E} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \cdot A^{\pi_{\theta_{\text{old}}}}(s, a) \right] \\ \text{s. t. } \mathbb{E} [D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta})] \leq \delta \end{array}}$$

이 식이 어디서 나오는지는 뒤에서: performance difference $\rightarrow$ KL bound $\rightarrow$ penalty를 constraint로 $\rightarrow$ 샘플 추정

- Step 크기를 **parameter 공간이 아니라 policy(분포) 공간**에서 제한 $\rightarrow$ 이론적으로 monotonic improvement 보장
- 남은 문제: **구현이 어렵다**. Fisher 행렬, conjugate gradient, line search 같은 2차 최적화가 필요
 - policy와 value가 파라미터를 공유하는 구조나 큰 모델에 적용하기 힘들다

1. TRPO: KL 제약이 왜 실제 개선을 보장하나

- ① 새 policy 성능을 옛 advantage로 **정확히** 표현 (performance difference). 단, 새 **policy의 상태 분포** d^{π_θ} 라 계산 불가

$$J(\pi_\theta) = J(\pi_{\text{old}}) + \mathbb{E}_{\tau \sim \pi_\theta} [\sum_t \gamma^t A^{\pi_{\text{old}}}(s_t, a_t)] = J(\pi_{\text{old}}) + \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_\theta}, a \sim \pi_\theta} [A^{\pi_{\text{old}}}(s, a)]$$

- ② 상태 분포만 $d^{\pi_\theta} \rightarrow d^{\pi_{\text{old}}}$ 로 바꾼 근사 L (행동은 아직 π_θ). $\pi_\theta = \pi_{\text{old}}$ 에서 J와 값, 기울기가 같다

$$L(\pi_\theta) = J(\pi_{\text{old}}) + \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_{\text{old}}}, a \sim \pi_\theta} [A^{\pi_{\text{old}}}(s, a)]$$

행동까지 π_{old} 샘플로 바꾸는 것(importance sampling)은 뒤에서

- ③ 바꿔치기한 오차는 두 policy가 멀수록 커지고, **KL로 bound된다** (Schulman et al., 2015)

$$J(\pi_\theta) \geq L(\pi_\theta) - C \cdot \max_s D_{\text{KL}}(\pi_{\text{old}}(\cdot | s) \parallel \pi_\theta(\cdot | s)), \quad C = \frac{4\varepsilon\gamma}{(1-\gamma)^2}$$

- ④ 우변 $M = L - C \cdot D_{\text{KL}}^{\max}$ 은 J의 하한이고 π_{old} 에서 J와 같다 $\rightarrow J(\pi_{\text{new}}) \geq M(\pi_{\text{new}}) \geq M(\pi_{\text{old}}) = J(\pi_{\text{old}})$, 단조 증가

엄밀한 보장은 max KL penalty 형태. 이론적 C로는 step이 너무 작아서, 실제 TRPO는 평균 $\text{KL} \leq \delta$ 제약으로 근사한다. $\varepsilon = \max |A^{\pi_{\text{old}}}(s, a)|$

1. TRPO: penalty에서 constraint로 (Lagrangian)

- 앞 장의 결론: **penalty** 꼴을 최대화하면 J 가 단조 증가 ($D_{\text{KL}}^{\max} := \max_s D_{\text{KL}}(\pi_{\text{old}}(\cdot|s) \parallel \pi_{\theta}(\cdot|s))$)

$$\max_{\theta} [L(\theta) - C \cdot D_{\text{KL}}^{\max}(\theta_{\text{old}}, \theta)], \quad C = \frac{4\epsilon\gamma}{(1-\gamma)^2}$$

- 문제: 이론적 C 는 매우 커서 step이 너무 작다 $\rightarrow C$ 대신 **얼마나 움직여도 되는지 δ** 를 직접 정하자 (constraint, 식 11)

$$\max_{\theta} L(\theta) \quad \text{s.t. } D_{\text{KL}}^{\max}(\theta_{\text{old}}, \theta) \leq \delta$$

- **같은 문제다: Lagrangian으로 보면** penalty 꼴이 나온다. multiplier β 가 C 자리를 차지

$$\mathcal{L}(\theta, \beta) = L(\theta) - \beta(D_{\text{KL}}^{\max}(\theta_{\text{old}}, \theta) - \delta), \quad \beta \geq 0$$

θ 로 최대화할 때 $\beta\delta$ 는 상수 $\rightarrow \max_{\theta} L - \beta \cdot D_{\text{KL}}^{\max}$: penalty와 같은 꼴. δ 를 정하면 대응하는 β^* 가 정해진다 (뒤의 KKT)

- 그래도 $\max_s$ 는 **모든 상태에서** $\text{KL} \leq \delta \rightarrow$ 너무 강하고 확인조차 어렵다 $\rightarrow$ **평균 KL**로 완화 (식 12)

$$\boxed{\max_{\theta} L(\theta) \quad \text{s.t. } \mathbb{E}_{s \sim d^{\pi_{\text{old}}}} [D_{\text{KL}}(\pi_{\text{old}}(\cdot|s) \parallel \pi_{\theta}(\cdot|s))] \leq \delta}$$

C (penalty)와 δ (constraint)는 같은 trade-off의 두 손잡이. δ 는 "policy가 얼마나 바뀌는가"로 바로 읽혀서 정하기 쉽다. 남은 일: 목적식 L 을 샘플로 계산하기

1. Importance sampling: 다른 분포의 샘플로 기댓값 구하기

- p 에 대한 기댓값을 구하고 싶은데 샘플은 다른 분포 q 에서만 있다

$$\mathbb{E}_{x \sim p}[f(x)] = \sum_x p(x)f(x)$$

기댓값의 정의

$$= \sum_x q(x) \frac{p(x)}{q(x)} f(x)$$

$q(x)/q(x) = 1$ 을 곱한다 ($q(x) > 0$ 이면 됨)

$$= \mathbb{E}_{x \sim q} \left[\frac{p(x)}{q(x)} f(x) \right]$$

q 에 대한 기댓값, 대가는 가중치 p/q

$$\approx \frac{1}{N} \sum_{i=1}^N \frac{p(x_i)}{q(x_i)} f(x_i), \quad x_i \sim q$$

샘플 평균으로 추정 (**unbiased**)

x	p(x)	q(x)	f(x)	가중치 p/q
1	0.9	0.5	1	1.8
2	0.1	0.5	0	0.2

정답 $\mathbb{E}_p[f] = 0.9$. q 샘플로: $0.5 \times 1.8 \times 1 + 0.5 \times 0.2 \times 0 = 0.9$

- **TRPO**: $p = \pi_\theta(\cdot|s)$, $q = \pi_{\text{old}}(\cdot|s)$, $f = A^{\pi_{\text{old}}}(s, \cdot)$
 - $\mathbb{E}_{a \sim \pi_\theta}[A] = \mathbb{E}_{a \sim \pi_{\text{old}}}[(\pi_\theta/\pi_{\text{old}}) A] \rightarrow$ 다음 장
- **주의**: p/q 가 크게 튀면 소수의 샘플이 추정을 지배 $\rightarrow$ 분산 폭발
 - 그래서 p 와 q 가 가까워야 한다 $\rightarrow$ TRPO의 KL 제약, PPO의 clip

1. TRPO: 샘플로 계산할 수 있는 objective로

- 앞 장의 문제 (식 12): $\max \mathbf{L}(\theta)$ s.t. 평균 $\text{KL} \leq \delta$. 제약은 그대로 두고 목적식 $\mathbf{L}$ 만 다룬다
- $\mathbf{L}$ 을 풀어 쓰고 (식 13, θ 와 무관한 $J(\pi_{\text{old}})$ 는 버림), 남은 합 두 개를 샘플로 추정할 수 있는 기댓값으로 바꾼다

$$\sum_s \rho^{\pi_{\text{old}}}(s) \sum_a \pi_{\theta}(a|s) A^{\pi_{\text{old}}}(s, a)$$

식 (13)의 목적식: 모든 상태, 모든 행동에 대한 합

$$= \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_{\text{old}}}} \left[\sum_a \pi_{\theta}(a|s) A^{\pi_{\text{old}}}(s, a) \right]$$

상태: $d^{\pi_{\text{old}}} = (1-\gamma) \rho^{\pi_{\text{old}}}$ 로 정규화 $\rightarrow \pi_{\text{old}}$ rollout의 상태로 **MC 추정**

$$= \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_{\text{old}}}, a \sim \pi_{\text{old}}} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\text{old}}(a|s)} A^{\pi_{\text{old}}}(s, a) \right]$$

행동: $\sum_a \pi_{\theta} f = \sum_a \pi_{\text{old}} (\pi_{\theta}/\pi_{\text{old}}) f \rightarrow$ **importance sampling**

- **TRPO가 실제로 푸는 문제:** 샘플로 계산하는 목적식 + 평균 KL 제약

$$\boxed{\max_{\theta} \mathbb{E}_{s \sim d^{\pi_{\text{old}}}, a \sim \pi_{\text{old}}} [r_{\theta}(s, a) \cdot A^{\pi_{\text{old}}}(s, a)] \quad \text{s.t.} \quad \mathbb{E}_{s \sim d^{\pi_{\text{old}}}} [D_{\text{KL}}(\pi_{\text{old}}(\cdot|s) \parallel \pi_{\theta}(\cdot|s))] \leq \delta}$$

최종 문제: 목적식 (식 13을 샘플 형태로) + 평균 KL 제약 (식 12). $r_{\theta} := \pi_{\theta}(a|s) / \pi_{\text{old}}(a|s)$, $1/(1-\gamma)$ 는 상수라 생략

= 첫 TRPO 슬라이드의 식. 목적식만 떼면 PPO의 L^{CPI} , PPO는 KL 제약을 clip으로 대신한다. 논문의 ρ 는 정규화 안 된 할인 방문 빈도

1. 정확한 PG와 TRPO surrogate: 무엇을 바꿔치기했나

$$\max_{\theta} \mathbb{E}_{s \sim d^{\pi_{\text{old}}}, a \sim \pi_{\text{old}}} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\text{old}}(a|s)} A^{\pi_{\text{old}}}(s, a) \right] \quad \text{s. t.} \quad \mathbb{E}_{s \sim d^{\pi_{\text{old}}}} [D_{\text{KL}}(\pi_{\text{old}}(\cdot | s) \parallel \pi_{\theta}(\cdot | s))] \leq \delta$$

TRPO가 실제로 푸는 문제 (앞 장). 아래 표: 정확한 PG와 비교해 무엇을 바꿨나

	정확한 PG	TRPO / PPO surrogate
상태 분포	$d^{\pi_{\theta}}$	$d^{\pi_{\text{old}}} \rightarrow$ 근사 (보정 없이 바꿔치기)
행동 분포	π_{θ}	$\pi_{\text{old}} + \text{ratio } \pi_{\theta}/\pi_{\text{old}} \rightarrow$ 정확히 보정
advantage	$A^{\pi_{\theta}}$	$A^{\pi_{\text{old}}}$
업데이트 크기	lr로만 조절	평균 $\text{KL} \leq \delta$ (PPO는 clip으로 대신)
$\theta = \theta_{\text{old}}$ 에서		세 가지가 모두 같아져 gradient가 정확한 PG와 일치

- **상태 쪽은 왜 보정 못 하나:** 새 policy가 어떤 상태를 방문할지 모른다 $\rightarrow$ 이 오차를 KL로 묶은 것이 앞 장의 Theorem 1, PPO clip은 근사가 유효한 범위에 머물게 하는 장치
- **실제 구현:** rollout의 (s_t, a_t) 를 쓰므로 상태는 할인 없는 방문 빈도 (γ^t 관련, Nota & Thomas), A는 GAE 추정치

1. TRPO의 실제 업데이트: natural gradient와 penalty 해석

- ① 풀어야 할 문제 (앞 장): L 은 J 의 근사가 아니라 이 식 그대로, KL은 상태에 대한 평균

$$\max_{\theta} L(\theta) \quad \text{s.t.} \quad \bar{D}_{\text{KL}}(\theta) \leq \delta$$

$$L(\theta) := \mathbb{E}_{s \sim d^{\pi_{\text{old}}}, a \sim \pi_{\text{old}}} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\text{old}}(a|s)} A^{\pi_{\text{old}}}(s, a) \right], \quad \bar{D}_{\text{KL}}(\theta) := \mathbb{E}_{s \sim d^{\pi_{\text{old}}}} [D_{\text{KL}}(\pi_{\text{old}}(\cdot|s) \parallel \pi_{\theta}(\cdot|s))]$$

- ② $\theta = \theta_{\text{old}} + \Delta$ 로 두고 L 은 1차, 평균 KL은 2차 근사 (θ_{old} 에서 $\text{KL} = 0$, $\nabla \text{KL} = 0$, Hessian = **Fisher F**)

$$\max_{\Delta} g^{\top} \Delta \quad \text{s.t.} \quad \frac{1}{2} \Delta^{\top} F \Delta \leq \delta, \quad g = \nabla_{\theta} L(\theta)|_{\theta_{\text{old}}} = \mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a|s) A^{\pi_{\text{old}}}(s, a)]$$

- ③ KKT: stationarity $g - \beta F \Delta = 0$, complementary slackness: 목적식이 선형이라 제약은 **항상 active** $\rightarrow \beta^* > 0$

$$\Delta^* = \frac{1}{\beta^*} F^{-1} g, \quad \beta^* = \sqrt{\frac{g^{\top} F^{-1} g}{2\delta}} \rightarrow \text{natural gradient step}$$

- ④ 문제: F 는 $\mathbf{N} \times \mathbf{N}$ ($\mathbf{N}$ = 파라미터 수). 저장 $O(\mathbf{N}^2)$, 역행렬 $O(\mathbf{N}^3) \rightarrow$ TRPO는 conjugate gradient + line search, 그래도 무겁다
- ⑤ **PPO부터는**: 제약을 **penalty $\beta \cdot \text{KL}$** 로 objective에 넣고 **1차 최적화**(Adam). adaptive KL = β 를 dual ascent로, clip = 더 단순한 근사

1. GAE: k-step advantage의 지수 가중평균

- A2C는 1-step δ_t 로 A를 추정했다. 일반화: k step까지는 실제 reward, 그 뒤는 critic V의 예측으로 채운 k-step advantage

$$\hat{A}_t^{(k)} = r_t + \gamma r_{t+1} + \dots + \gamma^{k-1} r_{t+k-1} + \gamma^k V(s_{t+k}) - V(s_t) = \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}$$

$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$. δ 들을 더하면 중간 V 항이 서로 상쇄된다 (telescoping)

- $k = 1$: δ_t (1-step TD) $\rightarrow$ V가 틀리면 **bias**, variance는 작다
- $k = \infty$: $G_t - V(s_t)$ (Monte Carlo) $\rightarrow$ bias 없음, **variance**가 크다
- k를 하나 고르지 않고 모든 k를 $(1-\lambda)\lambda^{k-1}$ 로 가중평균

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = (1 - \lambda) \sum_{k=1}^{\infty} \lambda^{k-1} \hat{A}_t^{(k)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

- $\lambda = 0 \rightarrow$ TD, $\lambda = 1 \rightarrow$ Monte Carlo, 보통 $\lambda \approx 0.95$. 계산은 뒤에서부터 한 번: $\hat{A}_t = \delta_t + \gamma \lambda \hat{A}_{t+1}$

다음 장 PPO의 $\hat{A}_t$ 가 이것. 모든 step에서 critic V가 필요하다 $\rightarrow$ LLM에서는 부담, GRPO는 $\lambda = 1$ 로 가되 V 대신 group 평균을 baseline으로 (2부 5장)

1. PPO: TRPO를 1차 최적화로 근사

$$L^{\text{KL PEN}}(\theta) = \mathbb{E}_t[r_t(\theta)\hat{A}_t - \beta D_{\text{KL}}(\pi_{\text{old}}(\cdot | s_t) \parallel \pi_{\theta}(\cdot | s_t))]$$

↓

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon)\hat{A}_t)]$$

$r_t(\theta) = \pi_{\theta}(a_t|s_t) / \pi_{\text{old}}(a_t|s_t)$. 위: TRPO의 KL 제약을 **penalty**로 (앞 장 ⑤), 아래: KL 대신 **ratio**를 $[1-\varepsilon, 1+\varepsilon]$ 로 직접 자른다

- Trust region을 근사하는 두 방법: **clipping** 또는 **adaptive KL penalty** (원 논문에서는 두 변형, clip이 더 좋았음)
- adaptive KL은 β 를 dual ascent로 조정, clip은 더 단순해서 사실상 표준. 전체 loss에는 **value loss**가 같이 들어간다

$$L = L^{\text{CLIP}} - c_1 L^{\text{VF}} + c_2 H[\pi_{\theta}], \quad L^{\text{VF}} = \mathbb{E}_t[(V_{\phi}(s_t) - V_t^{\text{targ}})^2]$$


$$V_t^{\text{targ}} := V_{\text{old}}(s_t) + \hat{A}_t, \quad \hat{A}_t = \sum_l (\gamma\lambda)^l \delta_{t+l}, \quad \delta_t = r_t + \gamma V_{\text{old}}(s_{t+1}) - V_{\text{old}}(s_t)$$

$\hat{A}_t$ 는 앞 장의 GAE. value net은 rollout으로 추정된 return (λ -return)을 맞춘다. $\lambda = 0$ 이면 $r_t + \gamma V(s_{t+1})$, $\lambda = 1$ 이면 G_t

$$\mathbb{E}[V_t^{\text{targ}} | s_t] = V_{\text{old}}(s_t) + \sum_l (\gamma\lambda)^l \mathbb{E}[\mathbb{E}[\delta_{t+l} | s_{t+l}] | s_t] = V^{\pi}(s_t)$$

target의 기댓값 = 실제 value: $V_{\text{old}} = V^{\pi}$ 이면 $\mathbb{E}[\delta | s] = 0$ (V의 Bellman), tower property로 모든 항이 0. $\lambda = 1$ 이면 항상 성립

1. PPO의 학습 루프: rollout 한 번, 업데이트 여러 번




회색 화살표: 같은 배치 D 를 매 업데이트에 재사용

```

for k = 0, 1, 2, ...
     $\theta_{\text{old}} \leftarrow \theta$           # 현재 policy를 old로 고정
     $D \leftarrow \text{rollout}(\pi_{\theta_{\text{old}}})$     # LLM: 질문마다 응답 G개
     $\log p_{\text{old}} \leftarrow \log \pi_{\text{old}}(a|s)$     # 저장, 이후 고정
     $\hat{A} \leftarrow \text{advantage}(D)$           # GAE 또는 group 평균, 한 번만
    for j = 1 ...  $\mu$           # epoch × minibatch
         $r \leftarrow \exp(\log \pi_{\theta} - \log p_{\text{old}})$  # 분자만 재계산
         $\theta \leftarrow \theta + \alpha \nabla_{\theta} L^{\text{CLIP}}(r, \hat{A})$ 
    # D는 버리고 다음 iteration
    
```

- π_{old} = 이번 배치를 만든 policy
- iteration 안: 데이터, π_{old} 고정, θ 만 이동
- 그래서 ratio가 필요, clip이 범위를 제한
- 첫 업데이트에서는 **ratio = 1**
- π_{old} 는 모델이 아니라 저장한 log-prob
- KL의 π_{ref} 는 학습 내내 고정된 초기 모델

1. PPO의 결과: 같은 예산에서 더 빨리, 더 높이



Schulman et al. (2017) Figure 3: MuJoCo 7개 환경, 100만 step. 보라색 = PPO (Clip)

- 대부분의 환경에서 **PPO가 가장 빨리, 가장 높이** 오른다 (Swimmer는 TRPO가 우세)
- A2C는 InvertedPendulum에서 만점 근처까지 갔다가 **크게 무너진다** → step size 문제의 실제 모습
- 단, PPO도 **단조 증가는 아니다** (InvertedDoublePendulum, Hopper). clip은 보장이 아니라 휴리스틱

1. 요약: 각 단계는 앞 단계의 문제 하나를 해결했다

방법	해결한 문제	핵심 장치	남은 문제
REINFORCE	샘플 기반 objective 최적화	log-derivative trick	높은 분산
A2C	분산	baseline $\rightarrow$ advantage, critic	step size에 민감
TRPO	불안정한 업데이트	KL trust region	2차 최적화, 구현 난이도
PPO	구현 난이도	clipping / adaptive KL, GAE, entropy bonus	이론 보장 약함 (경험적)

2. 게임 에이전트에서 LLM 후속학습으로

- 과거: 게임과 제어 환경 (Atari, MuJoCo, Go, Dota 2 — OpenAI Five는 PPO)
- 현재: 같은 알고리즘을 **LLM과 agent의 post-training**에 쓴다

RL 개념	게임 에이전트	LLM
state s_t	화면 / 관측	prompt + 지금까지 생성한 토큰
action a_t	조작 키	다음 토큰 (또는 tool call)
policy π_θ	정책 네트워크	LLM 자체
reward	게임 점수	reward model / 정답 검증 (주로 응답 끝에 한 번)
episode	한 판	응답 하나 (agent는 multi-turn trajectory)

다음 질문: LLM post-training에서 reward는 어디서 오는가?

3. RLHF: ChatGPT(InstructGPT)의 3단계






그림: OpenAI, Introducing ChatGPT (2022)

- **Step 1 SFT:** 사람이 쓴 시범 응답으로 지도학습
- **Step 2 Reward model:** 프롬프트당 응답 몇 개를 사람이 순위만 매긴다 → RM이 이 선호를 학습
- **Step 3 PPO:** 현재 모델이 새 응답을 만들면 RM이 채점 → 1장의 PPO로 업데이트
- **핵심:** 비싼 사람 라벨은 비교적 적은 비교 데이터를 한 번만 모으면 된다. 그 뒤는 RM이 사람 대신 채점

3. RLHF: reward model 학습과 PPO 루프



Reward model: 사람이 순위 매긴 응답으로 선호를 학습

PPO: 현재 모델의 응답을 RM이 채점 + 초기 모델과의 KL penalty

- 선호 데이터는 **고정된 오프라인 데이터**지만, PPO 단계는 **on-policy**: 매번 현재 모델이 새로 생성하고 RM이 채점
- 선호 데이터만으로 RM 없이 바로 **off-policy**로 학습하는 방법이 **DPO** (Rafailov et al., 2023)
- RM은 근사치라 **reward hacking** → KL penalty로 초기 모델 근처에 묶는다. 메모리에 모델 4개 (policy, reference, RM, critic)

3. RLAIIF: 선호 라벨을 AI가 만든다




Figure 2: A diagram depicting RLAIIF (top) vs. RLHF (bottom)

그림: Lee et al. (2023), RLAIIF (위) vs. RLHF (아래)

- 사람 대신 **기존 LLM이 응답 쌍을 평가**해 선호 라벨을 만든다 (Constitutional AI, Bai et al., 2022 / Lee et al., 2023)
- 나머지 파이프라인 (RM 학습 → RL)은 RLHF와 같다. 라벨 비용이 크게 줄어든다

3. RLVR: 검증 가능한 정답을 reward로


- Reinforcement Learning with Verifiable Rewards (Tulu 3, Lambert et al., 2024에서 이름 붙임)
- Reward를 **규칙으로 계산**: 수학 정답 일치, 코드 unit test 통과, 출력 형식 준수 → 보통 0/1
- 목표: 수학, 코드, 논리 같은 **추론 능력**
- 장점: 학습된 RM이 없어 RM 자체를 hacking할 여지가 적다. 라벨링이 싸고 대량으로 확장하기 쉽다
- 한계: 정답을 검증할 수 있는 도메인으로 제한. reward가 sparse하다 (응답 끝에 한 번)

3. 비교: reward를 어디서 얻는가

	RLHF / RLAIIF	RLVR
reward 출처	학습된 reward model (사람/AI 선호)	규칙 기반 verifier
목표	alignment (선호, 안전, 스타일)	reasoning (수학, 코드)
reward 형태	연속값, 노이즈 있음	0/1, 정확하지만 sparse
주요 위험	RM reward hacking	형식 hacking, 도메인 제한
대표 사례	InstructGPT, Claude (CAI)	Tulu 3, DeepSeek-R1, o1 계열

2부는 RLVR 쪽을 따라간다

3. LLM post-training의 구성 요소



- LLM을 중심으로 **prompt** → **response** → **reward model** → **reward** → **RL 알고리즘**이 한 바퀴 돈다 (+ regularization)
- **Response**: on-policy (GRPO) / off-policy (PPO) / offline (DPO) / SFT
- **Reward 출처**: 규칙 (RLVR) / AI 피드백 (RLAIF) / 사람 피드백 (RLHF)
- **Regularization**: KL로 초기 모델 근처에, entropy로 탐색 유지

그림: Wang et al., RL for LLM Post-Training: A Survey, Figure 1

서베이는 RLVR 방법들을 **prompt sampling**, **response sampling**, **gradient coefficient** 세 축으로 정리한다 → 2부를 읽는 틀

3. 하나의 policy gradient로 보기: gradient coefficient

$$\nabla_{\theta} J = \mathbb{E}_{(q,o) \sim D} \left[\frac{1}{|o|} \sum_t \text{GC}(q, o, t) \cdot \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) \right]$$

D : (q, o)를 어디서 뽑나, GC : 토큰마다 $\nabla \log \pi$ 에 곱하는 계수 (gradient coefficient)

방법	(q, o) 출처	reward	GC
Pretraining (MLE)	웹 텍스트	없음	1
SFT	사람이 쓴 (q, o)	없음	1
RFT / STaR (2부 4장)	$o \sim \pi_{\text{SFT}}$ (offline) 또는 π_{θ} (online)	정답 여부	1[o가 정답]
PPO (RLHF)	$o \sim \pi_{\theta}$	reward model + critic	$\hat{A}_t$ (GAE)
GRPO (RLVR, 2부 5장)	$o \sim \pi_{\theta}$, 질문당 G개	규칙 기반 0/1	group 정규화 $\hat{A}_i$

1장의 흐름도 GC로 읽힌다: REINFORCE는 $G_t \rightarrow \text{baseline}$ 을 빼면 $A \rightarrow$ PPO는 ratio와 clip이 곱해진 $\hat{A}$. 2부의 각 방법도 GC와 D를 어떻게 바꿨는지로 읽는다

1부 정리, 그리고 2부 예고

1부 정리

- Policy gradient = $\nabla \log \pi \times$ 계수. 1장은 그 계수의 분산을 줄이고 (baseline, GAE) 업데이트 크기를 제한하는 (TRPO, PPO) 역사
- LLM에서는 state = prompt + 토큰, action = 토큰, reward는 응답 끝에 한 번
- reward 출처로 **RLHF vs RLVR**이 갈리고, 모든 방법은 **GC와 데이터 출처만 다르다**

2부 (다음 시간)

- 4장 RL 이전의 추론 강화: Self-consistency, PRM, STaR
- 5장 DeepSeek-R1과 GRPO: 0/1 reward만으로 추론이 창발하는가
- 6장 Kimi k1.5, **DAPO (처음의 그 식 읽기)**, CISPO, Prefix-RFT
- 7장 ScaleRL, 8장 RL은 무엇을 학습하나 (Spurious rewards, CoDaPO), 9장 토론

We propose the **Decouple Clip** and **Dynamic sAmpling Policy Optimization** (DAPO) algorithm. DAPO samples a group of outputs $\{o_i\}_{i=1}^G$ for each question q paired with the answer a , and optimizes the policy via the following objective:

$$\begin{aligned} \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t}) \right] \\ \text{s.t. } & 0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G, \end{aligned} \quad (8)$$

where

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}, \quad \hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (9)$$

The full algorithm can be found in Algorithm 1. In this section, we will introduce the key techniques associated with DAPO.

처음에 본 이 식, 다음 시간에 한 줄씩 읽어 봅니다

참고 문헌 (1부)

- Bellman, 1957. Dynamic Programming
Sutton, 1988. Temporal difference learning
Watkins & Dayan, 1992. Q-learning
Rummery & Niranjan, 1994. SARSA
Puterman, 1994. Markov Decision Processes
Williams, 1992. REINFORCE
Sutton et al., 2000. Policy gradient theorem
Kakade, 2001. Natural policy gradient
Kakade & Langford, 2002. Approximately optimal approximate RL
Schulman et al., 2015. TRPO
Mnih et al., 2016. A3C / A2C
Schulman et al., 2016. GAE
Schulman et al., 2017. PPO
Sutton & Barto, 2018. Reinforcement Learning: An Introduction
Durrett, 2019. Probability: Theory and Examples
Mnih et al., 2015. DQN
Silver et al., 2016. AlphaGo
OpenAI, 2019. Dota 2 (OpenAI Five)
Ouyang et al., 2022. InstructGPT
OpenAI, 2022. Introducing ChatGPT (그림)
Lambert et al., 2022. Illustrating RLHF, Hugging Face (그림)
Bai et al., 2022. Constitutional AI
Lee et al., 2023. RLAIIF
Rafailov et al., 2023. DPO
Lambert et al., 2024. Tulu 3
Shao et al., 2024. DeepSeekMath
Wang et al., 2024. RL for LLM Post-Training: A Survey